

Thu thập & Tiền xử lý dữ liệu Bất động sản TP.HCM từ Nhà Tốt

Đồ án Data Science: Dự đoán giá, xác định bất thường giá cho nhà ở

Họ tên học viên

25/09/2026

Kết quả chính

47.928

tin thô, 22/22 quận

43.490

tin sạch sau tiền xử
lý

13

tháng lịch sử giá
theo phường

0,87

R^2 kiểm tra nhanh
(nhà ở)

- 3 loại BĐS: **31.390** nhà ở · **6.217** căn hộ · **5.883** đất
- Bao phủ trọn bộ dữ liệu mẫu giảng viên cung cấp (3 quận, nhà ở) và có đủ các cột của mẫu
- Bàn giao: dataset sạch, 22 file theo quận, 3 bộ train/test sẵn sàng cho mô hình

Mục tiêu & phạm vi

Bài toán của đề án

- Bài toán 1: dự đoán giá nhà (≥ 4 mô hình, cả sklearn và PySpark)
- Bài toán 2: phát hiện tin rao giá quá thấp / quá cao (4 tín hiệu $\rightarrow$ điểm 0–100)

Phần này đảm nhận

- Thu thập dữ liệu (crawler)
- Tiền xử lý đến mức *sẵn sàng cho mô hình*


Phạm vi dữ liệu

- 22 quận/huyện TP.HCM (địa giới cũ, trước sáp nhập 07/2025)
- Căn hộ, nhà ở, đất – tin *mua bán*
- Tin đang rao + tin đã gỡ / hết hạn
- Giữ cả tên phường cũ và phường mới

Giới hạn nguồn

Tin trên Chợ Tốt chỉ tồn tại ~ 60 ngày $\Rightarrow$ không lấy được tin 2 năm trước. Bù bằng **biểu đồ giá 13 tháng** + cào định kỳ.

Pipeline



Mỗi lần cào lưu vào `data/raw/<run_id>/` kèm `manifest.json`; nhật ký các lần cào:

`data/history/snapshots.csv.gz`

Thu thập dữ liệu

Tin rao (API ad-listing)

- Theo từng quận, 50 tin/trang, hết mọi trang
- Thêm tin đã gỡ $\Rightarrow$ **gần gấp đôi** (24,7 $\rightarrow$ 47,9 nghìn)
- Retry, thử lại trang lỗi, manifest.json

Biểu đồ giá (API market-price/charts)

- Đơn giá trung vị theo tháng, 13 tháng, theo phường $\times$ loại BĐS $\times$ phân nhóm
- 792 biểu đồ, gán cho **99,8%** số tin

Đối chiếu bộ dữ liệu mẫu

Nhà ở	Mẫu	Dataset này
Gò Vấp	4.374	3.404
Bình Thạnh	2.665	1.921
Phú Nhuận	1.234	908


Ít dòng hơn vì đã loại tin trùng; riêng file mẫu Gò Vấp có 216 tiêu đề trùng và 4,5% dòng trống.

Có đủ 22/23 cột của mẫu. **Không thu thập số điện thoại** (dữ liệu cá nhân).

Lỗi phát hiện & đã sửa trong code ban đầu

Vấn đề	Hậu quả	Cách sửa
Mã pháp lý dịch sai	Mã 6 = “Sổ hồng riêng” (căn hộ) bị ghi “Chưa xác định”	Dùng nhãn chữ của API, bảng mã tách theo loại BĐS
Gộp nhà, căn hộ, đất khi so giá	Đơn giá/m ² khác bản chất, ngoại lai sai	Ngưỡng + nhóm tham chiếu theo quận × loại BĐS
Ngưỡng đơn giá chung 5 tr/m ²	Loại oan ~11% tin đất (Củ Chi)	Ngưỡng riêng: đất 0,2 tr/m ²
Điền thiếu trước khi chia train/test	Rò rỉ dữ liệu; đất bị điền số phòng ngủ	Giữ NaN + cờ thiếu; điền thiếu fit trên train
Lỗi mạng trả trang rỗng	Mất phần còn lại của quận, không báo	Retry, thử lại trang lỗi, manifest
Bộ lọc “2 năm”	Không có tác dụng (tin chỉ sống 60 ngày)	Tin đã gỡ + biểu đồ giá 13 tháng

Làm sạch: loại 4.438 dòng (9,3%)



- **Trùng mềm:** cùng loại, phường, giá, diện tích, số phòng, số tầng → giữ tin sớm nhất; số bản trùng thành biến `n_duplicate_posts`
- Ngưỡng riêng cho từng loại BĐS
- Dòng bị loại lưu kèm lý do: `rejected_rows.csv`

Sửa từng ô: đặt NaN thay vì loại cả dòng

Giá trị phi lý	Số dòng
Tọa độ ngoài TP.HCM	63
Chiều ngang ≤ 0 hoặc > 50 m	100
Chiều dài ≤ 0 hoặc > 200 m	17
Căn hộ > 6 phòng ngủ	54
Nhà ở > 10 tầng	49
Số WC $>$ số phòng ngủ + 5	42
DT lệch ngang $\times$ dài > 2 lần (gần cờ)	472

Tọa độ chỉ ở mức đường / phường

Chợ Tốt không trả vị trí thật của căn nhà:

- **32.061** tin: tâm con đường
- **11.366** tin: tâm phường (1 điểm dùng chung cho nhiều đường)

⇒ biến `geo_precision`; không nên tính khoảng cách tới tiện ích ở mức mét.

Dữ liệu thiếu




Tỷ lệ thiếu dữ liệu (%) theo loại BĐS

	Nhà ở	Căn hộ	Đất
Phòng ngủ	1%	1%	không áp dụng
WC	29%	16%	không áp dụng
Số tầng	26%	không áp dụng	không áp dụng
Ngang	20%	không áp dụng	15%
Dài	23%	không áp dụng	19%
DT sử dụng	49%	không áp dụng	không áp dụng
Pháp lý	26%	22%	22%
Nội thất	53%	35%	không áp dụng
Hướng	75%	77%	69%
Dự án	không áp dụng	24%	không áp dụng
Tên đường	1%	0%	1%
Tọa độ	0%	1%	0%

- “Không áp dụng” $\neq$ thiếu: đất không có phòng ngủ, căn hộ không có số tầng nhà $\rightarrow$ để NaN, không điền
- Hướng nhà thiếu $\sim 75\%$, nội thất thiếu 35–53%
- Ở bước làm sạch: **không điền**, chỉ thêm cờ `*_missing`
- Điền trung vị / “missing” **chỉ fit trên train**

Phân phối giá

Phân phối đơn giá lệch phải -> dùng $\log(\text{giá})$ làm biến mục tiêu



- Đơn giá lệch phải mạnh $\Rightarrow$ biến mục tiêu $\text{target_log_price} = \ln(\text{giá tỷ đồng})$
- Đất có **hai đỉnh**: đất nông nghiệp ($\sim 1\text{--}10 \text{ tr/m}^2$) và thổ cư ($\sim 50\text{--}100 \text{ tr/m}^2$) $\Rightarrow$ `land_type` là biến bắt buộc

Đặc trưng bổ sung

Có cấu trúc (thay cho dò từ khóa)

- char_*: mặt tiền, hẻm xe hơi, nở hậu, quy hoạch, thổ cư...
- Nội thất, loại đất / căn hộ, dự án, phường mới


Giá khu vực

- bieu_do_gia (13 giá trị), tăng giá theo năm, tăng giá làm mượt

Giá thuê trích từ mô tả


- “cho thuê 40tr/tháng” → tỷ suất gộp: **2.994** tin, trung vị **3,0%/năm**

Biểu đồ giá 13 tháng (nhà ở) - 3 quận của bộ dữ liệu mẫu



Biểu đồ giá cấp phường còn nhiễu theo tháng → nên làm mượt hoặc gộp lên cấp quận.



EDA: đơn giá nhà ở theo quận



- Chênh lệch trên 20 lần giữa trung tâm (Q1 ~250 tr/m²) và Củ Chi (~10 tr/m²)
- ⇒ vị trí (quận, phường, đường) là nhóm biến quan trọng nhất
- Phường / đường / dự án có hàng nghìn giá trị → **Target Encoding**

EDA: tín hiệu đầu tư theo quận

Nhà ở: tín hiệu đầu tư theo quận



Ấn quận có ít hơn 100 tin (tăng giá) hoặc ít hơn 15 tin có giá thuê (tỷ suất) vì quá nhiều. Đây là số liệu mô tả, chưa phải khuyến nghị đầu tư.

Chuẩn bị dữ liệu cho mô hình

1. **Mỗi loại BĐS một bộ train/test riêng**
2. **Chia 80/20 theo người đăng**
(`account_id`): tin của cùng một môi giới rất giống nhau → nếu nằm ở cả hai tập thì đánh giá đẹp giả
3. **Loại ngoại lai chỉ trên train** ($3 \times \text{IQR}$ log đơn giá theo quận): 8 / 89 / 45 tin
4. **Fit trên train, áp dụng cho test:**
 - số: trung vị + chuẩn hóa
 - phân loại: One-Hot (gộp nhóm < 20)
 - phường / đường / dự án: Target Encoding cross-fitting


Không dùng làm biến đầu vào

Rò rỉ nhãn (tính từ chính giá):
đơn giá/m², tín hiệu bất thường S2/S3, giá thuê nêu trong tin

Chỉ biết sau khi đăng:
số ngày đăng, đã gõ, đã đẩy tin

	Train	Test	Biến
Căn hộ	4.956	1.253	91
Nhà ở	25.214	6.087	97
Đất	4.718	1.120	75

Kiểm tra nhanh: dữ liệu có đủ thông tin?



- HistGradientBoosting mặc định, **không tinh chỉnh**, đánh giá trên tập test
- Sai số giá trung vị: 12% (căn hộ), 14% (nhà ở), 20% (đất)
- Nhà ở, thang tỷ đồng: MAE 1,87 tỷ, RMSE 7,23 tỷ (vài căn rất đắt kéo RMSE lên) → báo cáo cả 2 thang
- 3 file mẫu: R^2 0,85, sai số trung vị 12%
- Mục đích: xác nhận dữ liệu dùng được, *không phải* kết quả mô hình cuối

Chuẩn bị cho bài toán 2: phát hiện giá bất thường

- **Giữ lại 177 tin nhà ở có giá phi lý** (bài toán 1 bỏ, nhưng đây là ca cần phát hiện)
- Nhóm tương đồng: **Phường × loại nhà** (hẻm / mặt phố / biệt thự...), ≥ 30 tin
- **S2 Min/Max**: khung sàn / trần từ biểu đồ giá 13 tháng của phường ($0,4 \times$ đáy; $2,5 \times$ đỉnh)
- **S3 P10–P90**: khoảng cách tương đối ra ngoài [P10, P90], chuẩn hóa [0, 1]
- **S1, S4** cần mô hình: đã có đặc trưng mã hóa sẵn cho mọi dòng, cột `if_*`, hàm tính S1 / S4 / điểm tổng hợp

Nhãn tham chiếu

146 tin nhà ở **Chợ Tốt** tự đánh dấu **giá không hợp lệ**: giá trung vị chỉ bằng 68% nhóm $\rightarrow$ nhãn cho “giá quá thấp”.
S2 bắt 8,2% số tin này, so với 1,9% ở tin thường (gấp 4 lần).

Nhà ở (31.567 tin)	Số tin
Vi phạm Min/Max (S2)	610
Ngoài P10–P90 – quá thấp	3.314
Ngoài P10–P90 – quá cao	3.321

Hai môi trường & hai lựa chọn dữ liệu

sklearn và PySpark dùng chung tập test

- `split.csv`: tin nào thuộc train / test
- sklearn: `train.parquet` đã mã hóa
- PySpark:
`pyspark_prep/chuan_bi_spark.py`
dựng pipeline Spark ML (Imputer, StringIndexer, OneHotEncoder, VectorAssembler) trên cùng tập train
- Mô hình học log(giá) → đổi về tỷ đồng bằng `exp()` rồi mới tính MAE / RMSE

Nếu chỉ phân tích 3 file mẫu

- `xu_ly_du_lieu_mau/xu_ly.py`: chuyển chuỗi sang số (“8,6 tỷ”, “900 triệu”, “nhiều hơn 10 phòng”), tách địa chỉ, bỏ số điện thoại
- 8.273 dòng → **7.256** tin sạch (309 dòng rỗng, 26 trùng hoàn toàn, 677 trùng cùng căn)
- Cùng tên cột, cùng đặc trưng và tín hiệu S2/S3 → **cùng code mô hình**
- Chia ngẫu nhiên theo quận (bộ mẫu không có mã người đăng)

Hạn chế & bước tiếp theo

Hạn chế

- Giá rao $\neq$ giá giao dịch
- Tin đã gỡ $\neq$ đã bán (có thể chỉ hết hạn)
- Tọa độ chỉ ở mức đường / phường
- Biểu đồ giá phường nhiều khi ít tin
- Nhãn tham chiếu bài toán 2 chỉ phủ “giá quá thấp”
- Phạm vi TP.HCM cũ, chưa gồm Bình Dương, Bà Rịa - Vũng Tàu

Bước tiếp theo

- Cào lại hàng tuần để tích lũy chuỗi thời gian
- Bước 4: ≥ 4 mô hình giá ở mỗi môi trường (Linear, Random Forest, XGBoost/LightGBM, GBT...), feature importance
- Bài toán 2: tính S1 (Residual-Z) và S4 (Isolation Forest), chọn trọng số $w1..w4$, ngưỡng top-k%
- Bước 6: triển khai web (vd. Streamlit)

Sản phẩm bàn giao

data/processed/nhatot_tphcm_clean.csv /
.parquet

Dataset sạch, 43.490 dòng

data/processed/by_district/,
by_property_type/

Chia theo 22 quận / 3 loại BĐS

data/processed/dinh_dang_mau/

Đúng tên cột của bộ dữ liệu mẫu

data/processed/market_price_monthly.csv

Giá khu vực theo tháng (13 tháng)

data/processed/rejected_rows.csv

Dòng bị loại + lý do

data/model_ready/<loại>/

Bài toán 1: train / test, split.csv,
preprocessor.joblib

data/anomaly_ready/<loại>/

Bài toán 2: S2, S3, if_*, đặc trưng mã hóa
sẵn

data/du_lieu_mau/

Kết quả xử lý riêng 3 file mẫu

reports/

Thống kê theo quận, tỷ lệ thiếu, biểu đồ

GHI_CHU_TIEN_XU_LY.md

Nhật ký quyết định tiền xử lý

BAO_CAO_TIEN_XU_LY.md

Danh mục biến